

مسئله اول

g_1, g_2

c_1, c_2, \dots, c_{16}

$$g_1 = \{-5, -4, -3, -2, -1, 1, 2, 3, 4, 5\} \rightarrow \{-5, 5\} - \{0\}$$

$$g_2 = \{25, 16, 9, 4, 1, 1, 4, 9, 16, 25\} \rightarrow \{x^2 | x \in g_1\}$$

$$55 - 30 = 25$$

(a) برای متغیرهای دو مرتبه را در یک خوشه قرار دادیم (معیار شباهت همیشگی)

$$\text{correlation} = \frac{\text{covariance}(x, y)}{\text{std}(x) * \text{std}(y)} = \frac{s_{xy}}{s_x * s_y}$$

$$\text{covariance} = s_{xy} = \frac{1}{n-1} \sum (x_k - \bar{x})(y_k - \bar{y})$$

$$s_x = \sqrt{\frac{1}{n-1} \sum (x_k - \bar{x})^2} = \sqrt{\frac{1}{10} (25 + 16 + 9 + 4 + 1)} = \sqrt{11}$$

$$\begin{cases} \text{mean}(x) = 0 \\ \text{mean}(y) = \frac{55 \times 2}{10} = 11 \end{cases}$$

$$s_y = \sqrt{\frac{1}{n-1} \sum (y_k - \bar{y})^2} = \sqrt{\frac{1}{10} (25^2 + 16^2 + 9^2 + 4^2 + 1)} = \sqrt{195.8}$$

$$\text{Correlation} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} = \frac{(-5)(25-11) + (-4)(16-11) + \dots + (1)(1-11)}{\sqrt{\Delta} \sqrt{\Delta}}$$

$$\text{correlation} = \frac{0}{\Delta}$$

$$\boxed{\text{correlation} = 0}$$

وقتی معیار correlation صفر شود
یعنی این که دو متغیر هیچ رابطه
خطی ای با هم ندارند.

پس حتی این نتیجه گیری، مشابه هم نیستند و نمی توان آن دو را در یک خوشه قرار داد.

ب) نهایی رتبه‌بندی (MI) را برای دو زبان محاسبه کنید : $MI = \sum \sum p(x, y) \log \frac{p(x, y)}{p(x) \cdot p(y)}$

$P(91) = \left\{ \frac{7}{10}, \frac{1}{10}, \frac{1}{10}, \dots, \frac{1}{10} \right\}$ $\begin{cases} p(x) \\ p(y) \end{cases}$
 $\xrightarrow{L=10}$ $p(x, y) \leftarrow$ احتمال تمام

$P(92) = \left\{ \frac{2}{10}, \frac{2}{10}, \frac{2}{10}, \frac{2}{10} \right\}$

-5 -4 -3 -2 -1 1 2 3 4 5

$P(91, 92)$

										$\frac{1}{10}$
25	$\frac{1}{10}$	0	0	0	0	0	0	0	0	$\frac{1}{10}$
16	0	$\frac{1}{10}$	0	0	0	0	0	0	$\frac{1}{10}$	0
9	0	0	$\frac{1}{10}$	0	0	0	0	$\frac{1}{10}$	0	0
4	0	0	0	$\frac{1}{10}$	0	0	$\frac{1}{10}$	0	0	0
1	0	0	0	0	$\frac{1}{10}$	$\frac{1}{10}$	0	0	0	0

نمونه MI :

$$= \left[p(-5, 25) \cdot \log \frac{p(-5, 25)}{p(-5) \cdot p(25)} \right] + p(-5, 16) \cdot \log \frac{p(-5, 16)}{p(-5) \cdot p(16)} +$$

$$p(-5, 9) \cdot \log \frac{p(-5, 9)}{p(-5) \cdot p(9)} + p(-5, 4) \cdot \log \frac{p(-5, 4)}{p(-5) \cdot p(4)} +$$

$$p(-5, 1) \cdot \log \frac{p(-5, 1)}{p(-5) \cdot p(1)} + p(-4, 25) \cdot \log \frac{p(-4, 25)}{p(-4) \cdot p(25)} +$$

$$p(-4, 16) \cdot \log \frac{p(-4, 16)}{p(-4) \cdot p(16)} + \dots + p(-2, 1) \cdot \log \frac{p(-2, 1)}{p(-2) \cdot p(1)}$$

۴۵. تمام این عبارت محاسبه شود \leftarrow احتمال تمام

Subject _____
Date _____

$$\begin{aligned} \rightarrow MI &= 0.1 * \log \frac{0.1}{0.1 * 0.2} + 0.1 * \log \left(\frac{0.1}{0.1 * 0.2} \right) + \\ &0.1 * \log \frac{(0.1)}{0.1 * 0.2} + 0.1 * \log \frac{0.1}{0.1 * 0.2} + 0.1 * \log \frac{0.1}{0.1 * 0.2} \\ &+ 0.1 * \log \frac{0.1}{0.1 * 0.2} + 0.1 * \log \frac{0.1}{0.1 * 0.2} + 0.1 * \log \frac{0.1}{0.1 * 0.2} \\ &+ 0.1 * \log \frac{0.1}{0.1 * 0.2} + 0.1 * \log \frac{0.1}{0.1 * 0.2} \end{aligned}$$

$$MI = 10 * \left(0.1 * \log \frac{0.1}{0.1 * 0.2} \right) = \log \frac{0.1}{0.1 * 0.2}$$

$$MI = \log \frac{0.1}{0.02}$$

$$MI = \log 5$$

$$MI = 0.698$$

Normalization \rightarrow

$$\frac{MI}{\sum p(x) \log \frac{p(x)}{N} + \sum p(y) \log \frac{p(y)}{N}}$$

$$0.698$$

$$\left(0.1 * \log \frac{0.1}{10} + \dots + 0.1 * \log \frac{0.1}{10} \right) * \left(0.2 * \log \frac{0.2}{10} + \dots + 0.2 * \log \frac{0.2}{10} \right)$$

$$\rightarrow \frac{MI = 0.698}{10 * 0.1 * (-2) + 10 * 0.2 * (-1.7)} = \frac{MI}{-2 * 2 * (-1.7)} = \frac{0.698}{6.8} \approx 0.1$$

Subject _____

Date _____

چون مقدار MI نزدیک - صفر شده است ← پس این دو بر دار تبعیت خیلی کمی دارند.

$MI < 1$
↓ ↓
تبعیت خیلی کم تبعیت خیلی زیاد

۶) تفاوتی در نتیجه مشاهده نمیکنیم

correlation این دو اثر صفر شد (عدم تبعیت)

اما در معیار MI ، مقدار کمی تبعیت برای آنها در نظر گرفته شده است.

Subject _____
Date _____

سؤال دوم

$$x = (1, 1, 1, 1)$$
$$y = (2, 2, 2, 2)$$

{ cosine (a
correlation
euclidean

$$A) \cos(x, y) = \frac{x \cdot y}{|x| \cdot |y|} = \frac{2 \times 1 + 2 \times 1 + 2 \times 1 + 2 \times 1}{|\sqrt{1^2 + 1^2 + 1^2 + 1^2}| \cdot |\sqrt{2^2 + 2^2 + 2^2 + 2^2}|}$$

$$\cos(x, y) = \frac{8}{\sqrt{4} \cdot \sqrt{16}} = \frac{8}{2 \times 4} = 1 \rightarrow \boxed{\cosine(x, y) = 1}$$

$$B) \text{correlation} = \frac{\text{covariance}(x, y)}{\text{std}(x) \cdot \text{std}(y)} = \frac{s_{xy}}{s_x \cdot s_y} = \frac{0}{0 \times 0} = \text{ترنس شده} = \%$$

correlation = unknown (undefined)

$$\text{correlation} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

$$\text{correlation} = \frac{[(2-2) \cdot (1-1)] \cdot [(2-2) \cdot (1-1)] \cdot [(2-2) \cdot (1-1)] \cdot [(2-2) \cdot (1-1)]}{\sqrt{0}}$$

$\sqrt{\text{mean}(x) = \frac{4}{4} = 1}$
 $\text{mean}(y) = \frac{8}{4} = 2$

c) euclidean

$$d = \sqrt{(2-1)^2 + (2-1)^2 + (2-1)^2 + (2-1)^2} = \sqrt{4} = 2$$
$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad \boxed{\text{euclidean} = 2}$$

$$x = (0, 1, 0, 1)$$

$$y = (1, 0, 1, 0)$$

A) cosine

$$\text{cosine}(x, y) = \frac{x \cdot y}{|x| \cdot |y|} = \frac{(1 \times 0) + (0 \times 1) + (1 \times 0) + (0 \times 1)}{\sqrt{1^2 + 1^2} \cdot \sqrt{1^2 + 1^2}} = \frac{0}{2 \cdot 2} = 0$$

$$\boxed{\text{cosine}(x, y) = 0}$$

cosine (b)
correlation
euclidean
jaccard

B) correlation

$$= \frac{\text{covariance}(x, y)}{\text{std}(x) * \text{std}(y)} = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} = \frac{4 \times \frac{25}{100}}{4 \times \frac{25}{100}} = 1$$

$$\text{mean}(x) = \frac{1}{4} (2) = \frac{1}{2}$$

$$\text{mean}(y) = \frac{1}{4} (2) = \frac{1}{2}$$

$$\boxed{\text{correlation} = 1}$$

$$\text{covariance}(x, y) = s_{xy} = \frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) = \frac{1}{3} \times \left[(0)(1 - \frac{1}{2}) + (1)(0 - \frac{1}{2}) + (0)(1 - \frac{1}{2}) + (1)(0 - \frac{1}{2}) \right] = \frac{1}{3} \times \left[0 - \frac{1}{2} + 0 - \frac{1}{2} \right] = \frac{1}{3} \times \left[-\frac{1}{2} - \frac{1}{2} \right] = \frac{1}{3} \times \left[-1 \right] = -\frac{1}{3}$$

$$s_x = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})^2} = \sqrt{\frac{1}{3} \left[\frac{(0-0.5)^2}{\frac{1}{4}} + \frac{(1-0.5)^2}{\frac{1}{4}} + \frac{(0-0.5)^2}{\frac{1}{4}} + \frac{(1-0.5)^2}{\frac{1}{4}} \right]} = \sqrt{\frac{1}{3}}$$

$$s_y = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (y_k - \bar{y})^2} = \sqrt{\frac{1}{3} \left[\frac{(1-0.5)^2}{\frac{1}{4}} + \frac{(0-0.5)^2}{\frac{1}{4}} + \frac{(1-0.5)^2}{\frac{1}{4}} + \frac{(0-0.5)^2}{\frac{1}{4}} \right]} = \sqrt{\frac{1}{3}}$$

C) Euclidean :

$$d = \sqrt{(1-0)^2 + (0-1)^2 + (1-0)^2 + (0-1)^2} = \sqrt{4} = 2$$

$$\boxed{\text{Euclidean} = 2}$$

$$d) \text{Jaccard} = \frac{\text{number of 11 matches}}{\text{number of non zero attributes}} = \frac{f_{11}}{f_{01} + f_{10} + f_{11}} = \frac{0}{2+2+0} = 0$$

$$\boxed{\text{Jaccard} = 0}$$

Subject _____

Date _____

$$x = (1, 1, 0, 1, 0, 1)$$

$$y = (1, 1, 1, 0, 0, 1)$$

- (C)
- manhattan
 - correlation
 - bhattacharyya

A) manhattan: $M = |1-1| + |1-1| + |0-1| + |1-1| + |0-0| + |1-1| = 2$

manhattan = 2

B) correlation = $\frac{\text{covariance}(x, y)}{\text{std}(x) \cdot \text{std}(y)} = \frac{S_{xy}}{S_x \cdot S_y} =$

mean(x) = $\frac{4}{6} = \frac{2}{3}$ $\text{std}(x) = \sqrt{\frac{1}{5} \left[\left(\frac{1}{3}\right)^2 + \left(\frac{1}{3}\right)^2 + \left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2 + \left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2 \right]}$

mean(y) = $\frac{4}{6} = \frac{2}{3}$ $\text{std}(y) = \sqrt{\frac{1}{5} \left[4 \times \frac{1}{9} + 2 \times \frac{4}{9} \right]} = \sqrt{\frac{1}{5} \times \frac{12}{9}} = \sqrt{\frac{4}{15}}$

covariance(x, y) = $S_{xy} = \frac{1}{n-1} \sum (x_k - \bar{x})(y_k - \bar{y}) = \frac{1}{5} \times \left[(1)(\frac{1}{3}) + (1)(\frac{1}{3}) + 1(-\frac{2}{3}) + 1(\frac{1}{3}) \right]$

$= \frac{1}{5}$

correlation = $\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} = \frac{(1-\frac{2}{3})(\frac{1}{3}-\frac{2}{3}) + (1-\frac{2}{3})(\frac{1}{3}-\frac{2}{3}) + (-\frac{2}{3}-\frac{2}{3}) + (\frac{1}{3}-\frac{2}{3})}{\sqrt{(\frac{1}{3})^2 + (\frac{1}{3})^2 + (\frac{2}{3})^2 + (\frac{1}{3})^2} \sqrt{(\frac{2}{3})^2 + (\frac{2}{3})^2 + (\frac{1}{3})^2}}$

→ correlation = $\frac{1}{4}$

C) Bhattacharyya = $-\ln \left(\sum_{i=1}^n \sqrt{x_i y_i} \right)$

$= -\ln(\sqrt{1 \times 1} + \sqrt{1 \times 1} + \sqrt{1 \times 0} + \sqrt{0 \times 1} + \sqrt{0 \times 0} + \sqrt{1 \times 1})$

$= -\ln(1+1+1)$

$= -\ln(3)$

$= -0.47$

→ Bhattacharyya = -0.47

Date _____

20*

- categorical کیفی \rightarrow { Nominal اسم
ordinal ترتیبی
- Numerical عددی \rightarrow { Interval باز
Ration $\frac{a}{b}$ \rightarrow True zero point

برای مطالعه، جمع و تفهیم و نسبت نهاد دارد — منشی است

چون نظریاتی فلسفی، کیفیت روشنی را به جز دسته تقسیم می کنند که توصیف کیفی می باشد.

(ب) این فرض که ناظر به حال قضاوت لفظی است نه عددی، اکثر قضاوت عددی کند مثل حکمت قبل است

$$\frac{60}{30} = 2$$

و چون نسبت برای آن معنا دارد، نسبت هم میتواند باشد.

Subject

Date

d) انتفاع از سطح اولیوس
نوع مقیاس: نسبی، کمی و بازه‌ای ← هیچ‌وقت فقط معنادار. fixed size
(متر)
نسبی ← نسبت معنادار

e) رتبه‌نظامی
نوع مقیاس: گسته، کیفی، ترتیبی
اسمی
همون یک سری کلاس با ranking است، بهین کیفی گسته است.
درجه‌های نظامی یک سری سلسله مراتب از پیش تعیین شده است ← گسته ی کیفی
قابل مقایسه اند ← ترتیبی

f) مدال‌های طلا و نقره و برنز در المپیک
نوع مقیاس: گسته، کیفی، ترتیبی
اسمی
همون یک سری کلاس با ranking است، کیفی گسته ترتیبی است.

نقشه: { هر مقیاس کمی نسبی، بازه‌ای نیز هست.
هر مقیاس کیفی ترتیبی، اسمی نیز هست.